

CF-MARLOS: یادگیری تقویتی چندعامله فدرال همکارانه با تجمیع آموختنی برای تشخیص نفوذ مجموعه‌باز در ترافیک B-NAT

محمد حسن امینی

دانشجوی کارشناسی ارشد، دانشگاه علم و صنعت ایران

m_amani79@cmps2.iust.ac.ir

چکیده

این مقاله چارچوب CF-MARLOS را برای تشخیص نفوذ در ترافیک B-NAT تحت یادگیری فدرال افقی و داده‌های غیرهمسان ارائه می‌کند. سامانه پیشنهادی سه جزء را به صورت هم‌زمان ترکیب می‌کند: عامل محلی CVAE-DQN برای طبقه‌بندی کلاس‌های شناخته‌شده، لایه تجمیع فدرال برای حفظ حریم خصوصی و مقیاس‌پذیری، و واسنجی EVT برای رد نمونه‌های ناشناخته. در این معماری، فقط پارامترهای یادگیری مشترک میان کلاینت‌ها فدرال می‌شوند؛ حافظه بازپخش، وضعیت بهینه‌ساز، داده خام و مصنوعات EVT محلی یا پس‌آموزشی باقی می‌مانند. پس از آموزش فدرال، مدل جهانی با خطاهای بازسازی نمونه‌های اعتبارسنجی درست طبقه‌بندی شده واسنجی می‌شود تا بتواند حملات دیده‌نشده را با آستانه‌ای کنترل شده رد کند. این طراحی برای بهبود هم‌زمان دقت کلاس‌های شناخته‌شده، پایداری تحت ناهمگنی کلاینتی، و تشخیص مجموعه باز مناسب است.

کلیدواژه‌ها: یادگیری فدرال، تشخیص نفوذ، تشخیص مجموعه باز، Double DQN، ترافیک B-NAT، EVT

۱ مقدمه

ترافیک B-NAT و سامانه‌های توزیع شده مشابه، به طور طبیعی در چندین گره، سازمان یا نقطه پایش جداگانه ذخیره می‌شوند. در چنین محیط‌هایی، متمرکز کردن داده خام همواره ممکن یا مطلوب نیست. یادگیری فدرال یک راه حل طبیعی فراهم می‌کند، اما قواعد تجمیع استاندارد مانند FedAvg در حضور توزیع‌های غیرهمسان می‌توانند ناپایدار شوند. دشواری مسئله در تشخیص نفوذ بیشتر می‌شود، زیرا مدل نه تنها باید حملات شناخته‌شده را طبقه‌بندی کند، بلکه باید حملات دیده‌نشده را نیز به درستی رد کند.

پیاده‌سازی این پروژه یک خط لوله ترکیبی را دنبال می‌کند که در آن یادگیری بازنمایی نهفته، Double DQN، مولد بازسازی، و EVT در یک معماری فدرال همکارانه ادغام شده‌اند. در این مقاله، CF-MARLOS به عنوان یک روش یکپارچه برای طبقه‌بندی مجموعه بسته، رد ناشناخته و آموزش فدرال تحت ناهمگنی کلاینتی ارائه می‌شود.

۲ پیشینه و صورت مسئله

در این چارچوب، هر کلاینت مجموعه داده محلی D_i را در اختیار دارد و داده خام را با سرور به اشتراک نمی‌گذارد. هدف فدرال، کمینه‌سازی مجموع وزن دار زبان‌های محلی است:

$$\min_{\Theta} \sum_{i=1}^N \frac{n_i}{\sum_j n_j} F_i(\Theta),$$

که در آن n_i تعداد نمونه‌های محلی کلاینت i است. در حالت FedProx، هدف محلی با جمله پروگزیمال به صورت زیر اصلاح می‌شود:

$$F_i^{\text{prox}}(\Theta) = F_i(\Theta) + \frac{\mu}{2} \|\Theta - \Theta^{k-1}\|_2^2.$$

برای تشخیص مجموعه باز، به جای اتکا به اعتماد نرم مجموعه بسته، از خطای بازسازی و مدل سازی دم EVT استفاده می‌شود. این کار به مدل اجازه می‌دهد تا نمونه‌هایی را که به توزیع کلاس‌های شناخته‌شده تعلق ندارند، با آستانه‌ای واسنجی شده رد کند.

۳ روش شناسی پیشنهادی

۱.۳ نمای کلی سامانه

شکل ۱ نمای کلی CF-MARLOS را نشان می‌دهد. ترافیک خام B-NAT از CSV به مصنوعات تانسوری تبدیل می‌شود، کلاس‌های شناخته‌شده به فضای برچسب ثابت نگاشت می‌شوند، و داده آموزش به قطعات کلاینتی غیرهمسان تقسیم می‌شود. هر کلاینت فقط قطعه خود را مشاهده می‌کند و عامل CVAE-DQN محلی را آموزش می‌دهد. سرور در هر دور فقط پارامترهای مدل یا خلاصه‌های ممیزی را دریافت می‌کند، آن‌ها را تجمیع می‌کند، و در پایان آموزش، مدل جهانی را با EVT واسنجی می‌کند. برای سازگاری میان نسخه انگلیسی و فارسی مقاله، همین شکل انگلیسی در هر دو نسخه استفاده شده است.

۲.۳ عامل محلی CVAE-DQN


فرض کنید $s \in \mathbb{R}^d$ بردار ویژگی ترافیک و $a \in \{1, \dots, C\}$ یکی از کلاس‌های شناخته‌شده باشد. هر کلاینت مسئله را به صورت یک فرمول بندی تقویتی مبتنی بر مخزن داده مدل می‌کند؛ در این فرمول بندی، کنش همان کلاس پیش‌بینی شده است و پاداش با درستی پیش‌بینی تعیین می‌شود.

عامل محلی از چهار مؤلفه اصلی تشکیل شده است:

- شبکه پیشین $p_{\theta}(z | s)$ برای نگاشت حالت به توزیع نهفته؛
 - شبکه بازشناسی $q_{\phi}(z | s, a)$ برای استنتاج نهفته وابسته به کلاس؛
 - شبکه اصلی $Q_{\psi}(z, s)$ برای انتخاب کلاس شناخته‌شده؛
 - شبکه هدف $Q_{\psi}^-(z, s)$ برای پایداری سازی Double DQN؛
 - مولد $G_{\omega}(z, a)$ برای بازسازی ویژگی‌ها.
- شبکه پیشین با شبکه بازشناسی هم تراز می‌شود:

$$L_{\text{prior}} = \text{KL}(q_{\phi}(z | s, a^*) || p_{\theta}(z | s)).$$

برای به روزرسانی θ ، از هدف $\theta \rightarrow \theta^*$ استفاده می‌شود:



شکل ۱: نمای کلی CF-MARLOS. پیش‌پردازش، قطعه‌های غیرهمسان کلاینتی، آموزش محلی CVAE-DQN، تجمیع فدرال، و استنتاج مجموعه‌باز مبتنی بر EVT.

جدول ۱: مؤلفه‌های فدرال شده و فدرال نشده در -

نقش	مؤلفه فدرال شده
بازنمایی نهفته مشترک	شبکه پیشین $p_\theta(z s)$
استنتاج نهفته و بازسازی	شبکه بازشناسی $q_\phi(z s, a)$
سیاست جهانی کلاس‌های شناخته‌شده	شبکه اصلی $Q_\psi(z, s)$
رفتار بازسازی مشترک	مولد $G_\omega(z, a)$
نقش	مؤلفه فدرال نشده
کپی محلی برای پایداری	شبکه هدف Q_ψ^-
تاریخچه محلی گذارها	حافظه بازپخش
وضعیت خصوصی آموزش	وضعیت بهینه‌ساز
مصنوعات واسنجی پس‌آموزشی	مدل‌ها و آستانه‌های
روی کلاینت باقی می‌ماند	داده خام کلاینت

۴.۳ اشتراک‌گذاری پارامترها

در - فقط پارامترهای یادگیری مشترک فدرال می‌شوند: این مرزبندی به حفظ حریم خصوصی، کاهش هزینه ارتباطی، و جلوگیری از تجمیع اشیای گذرای محلی کمک می‌کند.

۵.۳ FedProx و FedAvg به‌عنوان مینا

FedAvg از میانگین وزن‌دار بر اساس تعداد نمونه استفاده می‌کند:

$$a' = \arg \max_a Q_\psi(z', s', a),$$

$$y = r + \gamma(1 - d) Q_{\psi^-}(z', s', a').$$

$$L_{TD} = \text{Huber}(Q_\psi(z, s, a) - y).$$

بازپخش تجربه و سیاست ϵ -حریصانه برای یادگیری محلی استفاده می‌شوند. شبکه هدف فقط به‌صورت محلی همگام می‌شود و به‌عنوان یک مؤلفه فدرال مستقل ارسال نمی‌شود. اگر FedProx فعال باشد، جمله پروگزیمال زیر نیز به هدف محلی افزوده می‌شود:

$$L_{\text{prox}} = \frac{\mu}{2} \|\Theta_i - \Theta^{k-1}\|_2^2.$$

۳.۳ بازسازی مبتنی بر مولد

مولد پس از پیش‌بینی کلاس، نمونه را به‌صورت شرطی بازسازی می‌کند:

$$\hat{x} = G_\omega(z, \hat{a}), \quad e(x) = \frac{1}{d} \|x - \hat{x}\|_2^2 \cdot \kappa.$$

مولد فقط روی نمونه‌های شناخته‌شده و درست‌طبقه‌بندی‌شده آموزش داده می‌شود. این انتخاب باعث می‌شود فضای بازسازی به منیفولد کلاس‌های شناخته‌شده نزدیک بماند و خطای بازسازی برای نمونه‌های ناشناخته، سیگنال معنادارتری داشته باشد.

الگوریتم ۲ بهروزرسانی محلی CVAE-DQN با گزینه FedProx
ورودی: داده محلی D_i، پارامترهای پخش شده θ^{k-1}، پیکربندی محلی H، و ضریب پروگزیمال μ_i خروجی: پارامترهای بهروزشده θ_i^k و شاخص‌های ممیزی m_i^k ۱: θ^{k-1} را در Q_ψ, q_ϕ, p_θ و G_ω بارگذاری کن ۲: شبکه هدف را با $Q_\psi \leftarrow Q_\psi$ مقداردهی کرده و θ^{k-1} را مرجع FedProx قرار بده ۳: حافظه بازپخش B_i و سیاست ϵ-حریصانه π_i را مقداردهی کن ۴: برای هر اپیزود محلی انجام بده ۵: با محیط محلی تعامل کن و گذارهای $(s_t, a_t, r_t, s_{t+1}, d_t, a_t^*)$ را در B_i ذخیره کن ۶: اگر B_i کافی باشد آنگاه ۷: یک مینی‌بچ از B_i نمونه‌گیری کن ۸: p_θ را با L_{prior} و در صورت فعال بودن با جریمه FedProx بهروزرسانی کن ۹: q_ϕ و Q_ψ را با L_{TD} و در صورت فعال بودن با جریمه FedProx بهروزرسانی کن ۱۰: Q_ψ را به‌صورت نرم یا دوره‌ای از Q_ψ همگام کن ۱۱: اگر $\square\square\square$ ۱۲: $\square\square\square$ برای ۱۳: مجموعه نمونه‌های شناخته‌شده و درست طبقه‌بندی‌شده را بساز ۱۴: اگر آموزش مولد فعال باشد آنگاه ۱۵: G_ω را فقط روی نمونه‌های شناخته‌شده و درست طبقه‌بندی‌شده آموزش بده ۱۶: اگر $\square\square\square$ ۱۷: بازگردان $\theta_i^k = \{\theta_p, \theta_r, \theta_Q, \theta_G\}$ و m_i^k

الگوریتم ۱ آموزش فدرال CVAE-DQN و واسنجی مجموعه‌باز
ورودی: مجموعه داده‌های کلاینت‌ها $\{D_i\}_{i=1}^N$، مجموعه اعتبارسنجی D_{val}، تعداد دورها K، پیکربندی محلی H، و راهبرد $S \in \{\text{FedAvg}, \text{FedProx}, \text{FMRL-LA}\}$ δ رد آستانه و M_{evt} مدل‌های θ^* نهایی مدل خروجی: ۱: کن مقداردهی را $\theta^0 = \{\theta_p^0, \theta_r^0, \theta_Q^0, \theta_G^0\}$ اولیه پارامترهای ۲: بده انجام $k = 1 \dots K$ برای ۳: آن‌ها به θ^{k-1} و کرده نمونه‌گیری را C_k کلاینت‌های سرور می‌کند پخش ۴: بده انجام موازی به‌صورت $i \in C_k$ هر برای ۵: $\mu_i \leftarrow \mu$ اگر $S = \text{FedProx}$ $\mu_i \leftarrow 0$ ۶: $(\theta_i^k, m_i^k) \leftarrow \square\square\square\square\square\square\square\square\square\square\square\square(D_i, \theta^{k-1}, H, \mu_i)$ ۷: برای $\square\square\square$ ۸: آنگاه $S = \text{FMRL-LA}$ اگر ۹: $\theta^k \leftarrow \square\square\square\square\square\square\square\square\square\square\square\square(\theta^{k-1}, \{(\theta_i^k, m_i^k)\})$ ۱۰: وگر نه ۱۱: $\theta^k \leftarrow \frac{\sum_{i \in C_k} n_i \theta_i^k}{\sum_{i \in C_k} n_i}$ ۱۲: اگر $\square\square\square$ ۱۳: $\theta^* \leftarrow \theta^K$ ۱۴: $(M_{\text{evt}}, \delta) \leftarrow \square\square\square\square\square\square\square\square\square\square\square\square(D_{\text{val}}, \theta^*)$ ۱۵: بازگردان $\theta^*, M_{\text{evt}}, \delta$

۷.۳ واسنجی EVT و استنتاج مجموعه باز

پس از آموزش فدرال، مدل جهانی با EVT واسنجی می‌شود. فقط نمونه‌های اعتبارسنجی شناخته‌شده و درست طبقه‌بندی‌شده برای برازش دم استفاده می‌شوند. برای هر کلاس، دم بالایی خطای بازسازی با توزیع پارتوی تعمیم‌یافته مدل می‌شود و سپس احتمال ناشناختگی محاسبه می‌گردد:

$$P_{\text{unknown}}(x) = M_{\text{EVT}, \hat{a}}(e(x)).$$

آستانه جهانی δ_{global} از داده اعتبارسنجی تنظیم می‌شود. در زمان استنتاج، اگر

$$P_{\text{unknown}}(x) < \delta_{\text{global}},$$

نمونه به‌عنوان کلاس شناخته‌شده پذیرفته می‌شود؛ در غیر این صورت به‌عنوان ناشناخته رد می‌شود. این مرحله مدل را از طبقه‌بند مجموعه بسته به آشکارساز نفوذ مجموعه باز تبدیل می‌کند.

۸.۳ الگوریتم‌ها

شبه‌کدهای اصلی این روش در چهار الگوریتم بالا ارائه شده‌اند. الگوریتم ۱ جریان کامل آموزش فدرال و واسنجی نهایی را خلاصه می‌کند. الگوریتم ۲ بهروزرسانی محلی CVAE-DQN را با یا بدون FedProx مشخص می‌کند. الگوریتم ۳ قاعده انتخاب و تجمیع FMRL-LA را توضیح می‌دهد. الگوریتم ۴ نیز برازش EVT و تصمیم‌گیری مجموعه‌باز در مرحله استنتاج را نشان می‌دهد.

$$\Theta^k = \sum_{i \in C_k} \frac{n_i}{\sum_{j \in C_k} n_j} \Theta_i^k.$$

FedProx همان منطق سمت سرور را حفظ می‌کند، اما با جمله پروگزیمال، انحراف بهروزرسانی‌های محلی را محدود می‌سازد. FedAvg و FedProx در این مقاله مبنا هستند و به‌عنوان مشارکت اصلی روش پیشنهادی تلقی نمی‌شوند.

۶.۳ تجمیع همکارانه FMRL-LA

FMRL-LA مؤلفه نوآورانه اصلی این کار است. این روش به‌جای فرض مساوی بودن تمام کلاینت‌ها، سودمندی هر کلاینت را پیش از تجمیع برآورد می‌کند. در فاز $\square$ ، کلاینت‌ها محلی آموزش می‌بینند و فراداده ممیزی شامل پاداش، $\square$ ، دقت، پایداری، $\square$ ، نوآوری مبتنی بر $\square$ ، آنتروپی، پوشش برچسب، کیفیت مولد و تعداد گام‌ها را ارسال می‌کنند. سرور این اطلاعات را با یک منتقد ناهمگام ارزیابی می‌کند و امتیاز سودمندی u_i را به دست می‌آورد. در فاز $\square$ ، کلاینت‌های منتخب وزن‌های ذخیره‌شده را می‌فرستند و سرور دلتاهای پارامتری را با وزن سودمندی تجمیع می‌کند:

$$\Delta_i = \Theta_i^k - \Theta^{k-1}, \quad \Theta^k = \Theta^{k-1} + \eta \frac{\sum_{i \in A_k} u_i \Delta_i}{\sum_{i \in A_k} u_i}.$$

این طرح، به‌ویژه در داده‌های غیرهمسان، می‌تواند پایداری و کارایی ارتباطی را بهتر کند. در مقابل، هزینه آن افزایش هماهنگی است، زیرا هر دور منطقی شامل دو فاز جداگانه است.

